

Reporte Ejecutivo

Proyecto Final - Machine Learning con PySpark y Docker - 2026-I

Estudiante: Sergio Huertas

Repositorio: github.com/chechitoooo/proyecto_final_Huertas_Sergio

1. Resumen ejecutivo

Este proyecto trabaja con dos fuentes de datos colombianas. La primera es el dataset TUSO del catastro de Bogotá, que contiene 1.060.001 predios con tres columnas: código del lote, tipo de uso y área en metros cuadrados. La segunda es un corpus de 204 comentarios ciudadanos sobre alcaldías, ministerios, TransMilenio y servicios públicos. Los hallazgos principales son tres: el 68,1 % de los predios de Bogotá son de uso residencial con un área promedio de 187,13 m²; en la clasificación supervisada, la Regresión Logística alcanzó un accuracy de 0,83 y AUC de 0,88 sobre 211.930 predios de prueba; y en el análisis de sentimiento, el modelo TF-IDF con Regresión Logística obtuvo un accuracy de 0,83 y F1 de 0,83 sobre el corpus institucional, coincidiendo con HuggingFace en 4 de 5 casos de prueba.

2. Qué hice en cada bloque y por qué

Bloque 1. Análisis exploratorio sobre TUSO. Cargué el dataset en PySpark (1.060.001 filas) y lo exploré con seis tareas. Clasifiqué los predios por tamaño (pequeño: 309.816, mediano: 694.456, grande: 55.729), calculé estadísticas descriptivas con `describe()` y `summary()`, revisé si había nulos o duplicados (no había) e identifiqué valores atípicos. También hice dos gráficos con Matplotlib: un histograma de áreas y un gráfico de barras por tipo de uso. Usé PySpark en vez de pandas porque un millón de registros no caben cómodos en memoria local.

Bloque 2. Machine learning sobre TUSO. Construí un pipeline con `StringIndexer`, `OneHotEncoder`, `VectorAssembler` y `StandardScaler`. Elegí `StandardScaler` en lugar de `MinMaxScaler` porque los predios tienen áreas enormes (hasta 2,8 millones de m²) que aplastarían la escala del `MinMax`, y porque PCA necesita datos centrados en cero. En la parte no supervisada apliqué PCA (la varianza se concentra en los primeros componentes: PC1 explica 0,0021 y PC2 explica 0,0011) y K-Means con el método del codo (K=3 óptimo). Los tres clústeres encontrados fueron: cluster 0 con 578.717 predios de área promedio 187 m², cluster 1 con 312.773 predios de 61 m², y cluster 2 con 168.511 predios de 1.103 m². En la parte supervisada definí una variable objetivo binaria: predio residencial (USOTUSO=1, 721.963 casos) o no residencial (338.038 casos). Dividí en train (848.071) y test (211.930) con semilla 42. Entrené Regresión Logística y Random Forest, reporté métricas, hice matriz de confusión y extraje la importancia de variables. Por último corrí validación cruzada con `CrossValidator` sobre 9 combinaciones de hiperparámetros (`numTrees` y `maxDepth`).

Bloque 3. NLP sobre corpus institucional. Armé un corpus de 204 documentos simulando tweets reales sobre instituciones públicas colombianas (TransMilenio, alcaldías, ministerios, policía, salud). Tokenicé con `RegexTokenizer` y filtré 179 stop words en español. El corpus resultó en 1.422 tokens totales con un vocabulario de 854 palabras distintas (TTR de 0,60) y 609 hapax legomena. Vectoricé con `CountVectorizer` más IDF y comparé los rankings de frecuencia cruda contra TF-IDF. Luego usé el modelo preentrenado de HuggingFace (robertuito, de la Universidad de Buenos Aires) para etiquetar el corpus: 57 positivos, 69 negativos y 78 neutros. Filtré los neutros y sobre 126 documentos etiquetados entrené Regresión Logística con vectores TF-IDF (96 en train, 30 en test).

Por último comparé ambos enfoques con 5 casos difíciles de sarcasmo y frases ambiguas.

3. Resultados clave

Hallazgo 1 (Bloque 1). De los 1.060.001 predios, 721.963 (el 68,1 %) son de uso residencial (código 1), con un área promedio de 187,13 m². La media general del dataset es 295,56 m², la mediana es 158,7 m² y la desviación estándar es 3.082,43 m². El máximo registrado es 2.799.947,8 m² y hay 6.046 predios con más de 5.000 m². La diferencia entre la media (295) y la mediana (159) confirma que unos pocos predios enormes jalan la media hacia arriba, lo cual justificó aplicar logaritmo del área en el Bloque 2.

Hallazgo 2 (Bloque 2). La Regresión Logística superó claramente a Random Forest. Sobre el conjunto de prueba de 211.930 predios, LR obtuvo accuracy de 0,83, F1 de 0,82 y AUC de 0,88. Random Forest quedó en accuracy de 0,68, F1 de 0,55 y AUC de 0,74. La matriz de confusión de LR muestra 40.177 verdaderos negativos, 134.815 verdaderos positivos, 27.498 falsos positivos y 9.440 falsos negativos. El modelo tiende a equivocarse más prediciendo residencial cuando no lo es (tasa FP del 40,6 %) que al revés (tasa FN del 6,5 %). En cuanto a importancia de variables, `area_cat` fue la más relevante con 0,1785, seguida de `log_area` con 0,1197 y `USOAREA` con 0,0716. La validación cruzada dio como ganador Random Forest con 50 árboles y profundidad máxima de 10 (AUC en CV de 0,80).

Hallazgo 3 (Bloque 3). El modelo TF-IDF con Regresión Logística alcanzó un accuracy de 0,83 y F1 de 0,83 sobre los 30 documentos de prueba. La matriz de confusión muestra 15 negativos correctos, 10 positivos correctos, 2 falsos positivos y 3 falsos negativos. Las palabras que más pesan para positivo son "rápidos", "eficientes" y "nutrición"; las que más pesan para negativo son "robaron", "celular" y "altísimos". En los 5 casos de prueba contra HuggingFace, ambos modelos coincidieron en 4 de 5. Donde difirieron fue en una frase con sarcasmo: "Buenísimo el aumento de impuestos" fue clasificada como NEG por TF-IDF pero como POS por HuggingFace, evidenciando que el modelo clásico no captura la ironía. Al probar con 5 casos adicionales de sarcasmo y negaciones, la coincidencia bajó a 1 de 5, confirmando que TF-IDF falla sistemáticamente con lenguaje no literal.

4. Cómo se conectan los tres bloques

Los tres bloques cuentan una historia. El Bloque 1 me obligó a conocer los datos antes de modelar: vi que el área tiene una cola muy larga hacia la derecha y que el 68 % de los predios son residenciales. Esa observación me llevó a crear variables derivadas como `log_area` y `area_cat` en el Bloque 2, y funcionó: la Regresión Logística alcanzó un AUC de 0,88 con solo cuatro variables. Además el Bloque 2 me mostró que `area_cat` y `log_area` son las variables más importantes, mientras que el sector geográfico aporta poco (importancia de 0,026). El K-Means reveló tres grupos naturales de predios: pequeños (61 m² promedio), medianos (187 m²) y grandes (1.103 m²), alineados con la clasificación manual del Bloque 1. El Bloque 3 me llevó al otro extremo: los textos. Ahí el área no sirve de nada y lo que importa es el contexto. Un modelo clásico como TF-IDF funciona bien en casos simples (4 de 5 aciertos), pero falla estrepitosamente con sarcasmo e ironía (1 de 5 aciertos). La conclusión práctica es que no hay un único modelo que sirva para todo. Si voy a hacer avalúos catastrales, necesito un modelo interpretable como Regresión Logística, donde cada coeficiente me diga qué variable pesa más. Si voy a monitorear redes sociales para una alcaldía, necesito un transformer que entienda el tono real de los ciudadanos, aunque pese 500 MB. Un sistema maduro usaría los dos.

5. Limitaciones honestas de mi análisis

Corpus sintético del Bloque 3. Los 204 documentos los armé yo simulando tweets reales. Aunque reflejan temas auténticos del debate público colombiano, no fueron validados por otras personas ni capturan toda la diversidad de opiniones que hay en redes sociales.

Etiquetas prestadas. Las etiquetas de sentimiento las puso robertuito, no un humano. Si el modelo preentrenado tiene sesgos, ese sesgo se transmite al clasificador TF-IDF. Para estar seguros habría que anotar manualmente al menos 500 ejemplos.

Pocas variables en TUSO. El dataset solo trae tres columnas. Con datos adicionales como avalúo catastral, estrato o coordenadas (disponibles en el IDECA), los modelos del Bloque 2 probablemente superarían un AUC de 0,90.

6. Qué le diría a alguien que quiera seguir este trabajo

Use el Dockerfile del repositorio. Con docker-compose up se levanta Jupyter con Spark 3.5.0 y todas las dependencias. Ejecute los notebooks en orden: primero el de EDA, luego el de ML y por último el de NLP.

Para mejorar los resultados: reemplace el corpus sintético del Bloque 3 por tweets reales, mínimo 2.000. Cruce TUSO con otras fuentes del IDECA para agregar variables al modelo. Pruebe XGBoost de Spark ML como alternativa a Random Forest. Para producción, la estrategia de knowledge distillation funciona: use HuggingFace para etiquetar datos nuevos automáticamente y entrene periódicamente un modelo TF-IDF ligero que corra rápido.