

Reporte Ejecutivo — Proyecto Final

Machine Learning con PySpark y Docker · 2026-I

Estudiante: Sergio Huertas

Repositorio: github.com/chechitoooo/proyecto_final_Huertas_Sergio

1. Resumen Ejecutivo

Este proyecto aplica un flujo completo de ciencia de datos sobre dos problemas reales del contexto colombiano. El primero es el análisis del uso del suelo en Bogotá a partir del dataset TUSO del catastro distrital, que contiene 1.060.001 predios con su código de lote (USOCLOTE), tipo de uso (USOTUSO, un código numérico del 1 al 99) y área en metros cuadrados (USOAREA). El segundo es el análisis de sentimiento sobre un corpus de 204 comentarios ciudadanos acerca de alcaldías, ministerios, TransMilenio y servicios públicos colombianos. Los tres hallazgos principales son: (1) el 68,1 % de los predios de Bogotá son de uso residencial con un área promedio de 187,13 m²; (2) el área del predio explica más del 95 % de la capacidad predictiva en la clasificación de uso, alcanzando un AUC de 0,79 con Random Forest; y (3) los modelos pre-entrenados de Hugging Face detectan sarcasmo y ambigüedad en opiniones ciudadanas que el pipeline clásico TF-IDF + Regresión Logística no logra capturar.

2. Metodología

Bloque 1 — Análisis Exploratorio de Datos (EDA)

Se cargó el dataset TUSO.csv en PySpark y se realizaron seis tareas: carga con inferencia de esquema, transformaciones analíticas (clasificación de predios por tamaño —pequeño/mediano/grande—, agregaciones por tipo de uso, extracción del sector geográfico desde USOCLOTE y filtrado de predios atípicos), estadística descriptiva (media, mediana, desviación estándar, percentiles), detección de valores nulos (cero en las tres columnas), duplicados (cero) y atípicos (6.046 predios con más de 5.000 m²), visualizaciones con Matplotlib (histograma de áreas y barras por tipo de uso) y una celda Markdown con tres conclusiones cuantitativas. Se eligió PySpark porque 1.060.001 registros exceden la memoria de pandas en un entorno local.

Bloque 2 — Machine Learning con Spark ML

Se construyó un pipeline de preparación con StringIndexer (codifica el sector geográfico a numérico), OneHotEncoder (evita ordinalidad falsa entre sectores), VectorAssembler (junta USOAREA, log_area, area_cat y sector_ohe en un vector) y StandardScaler (elegido sobre MinMaxScaler porque los outliers extremos comprimirían MinMaxScaler y PCA requiere datos centrados en cero). En la parte no supervisada se aplicó PCA sobre los 4 features originales, reportando la varianza explicada por cada componente, y K-Means con el método del codo (9 clusters óptimos). En la parte supervisada se definió una variable objetivo binaria: USOTUSO = 1 (residencial, 68 % de la muestra de 100.000 registros) vs. resto. Se entrenaron Regresión Logística y Random Forest sobre un split 80/20 con semilla 42, reportando accuracy, precision, recall, F1 y AUC. Se extrajo la matriz de confusión y la importancia de variables. Finalmente se aplicó CrossValidator con grid de numTrees × maxDepth (9 combinaciones × 3 folds = 27 entrenamientos).

Bloque 3 — NLP y Modelo Pre-entrenado

Se construyó un corpus sintético de 204 documentos (tweets y comentarios) sobre instituciones públicas colombianas, abarcando TransMilenio, alcaldías, ministerios, policía, salud, educación y corrupción. En la Parte A se aplicó tokenización con `RegexTokenizer` (patrón `\W+`, lowercase) y filtrado de 179 stop words en español incluidas en Spark, reportando total de tokens, vocabulario, Type-Token Ratio (TTR) y hapax legomena (palabras que aparecen una sola vez). En la Parte B se vectorizó con `CountVectorizer` (`minDF=2`, `vocabSize=2000`) + IDF y se compararon los rankings de frecuencia cruda (TF) versus TF-IDF. En la Parte C se etiquetó el corpus mediante knowledge distillation con el modelo pre-entrenado `pysentimiento/robertuito-sentiment-analysis` (Universidad de Buenos Aires, entrenado sobre tweets en español), filtrando a clases POS y NEG, y se entrenó Regresión Logística sobre los vectores TF-IDF para evaluar si un modelo ligero puede aprender del teacher model. En la Parte D se compararon ambos enfoques (TF-IDF+RL vs. HuggingFace) con 8 casos diseñados para probar sarcasmo, ambigüedad y negaciones.

3. Resultados Clave

Hallazgo 1 — Bloque 1: El 68,1 % del dataset (721.963 de 1.060.001 predios) corresponde al tipo de uso código 1 (residencial), con un área promedio de 187,13 m², inferior al promedio general de 295,56 m². La mediana se ubica en 158,7 m² y el percentil 75 en 248,4 m², lo que indica una distribución concentrada en predios pequeños y medianos. La desviación estándar de 3.082,43 m² —diez veces la media— y el valor máximo de 2.799.947,8 m² confirman una cola derecha extrema con 6.046 predios superando los 5.000 m². Este hallazgo justifica la transformación logarítmica (`log_area`) aplicada en el Bloque 2 para estabilizar la varianza antes del modelado.

Hallazgo 2 — Bloque 2: El área del predio domina la predicción: en Random Forest las variables `USOAREA` y `log_area` suman el 79,7 % de la importancia total (39,6 % y 40,1 % respectivamente), mientras que `area_cat` aporta el 16,0 % y el sector geográfico (`sector_ohe`) apenas un 4,3 %. Ambos modelos —Regresión Logística y Random Forest— obtienen rendimiento similar: accuracy 0,78 y F1 0,85 para RF, con AUC-ROC de 0,78. La matriz de confusión revela que el modelo se equivoca principalmente en la clase 'No residencial' (tasa de falsos positivos del 60,1 %), prediciendo erróneamente como residenciales muchos predios que no lo son. La validación cruzada seleccionó `numTrees = 100` y `maxDepth = 15` como configuración óptima (AUC en CV = 0,7878), superando ligeramente a `maxDepth = 10` (AUC = 0,7846).

Hallazgo 3 — Bloque 3: La Regresión Logística sobre TF-IDF obtuvo accuracy de 0,60 y F1 de 0,71, con sesgo hacia la clase mayoritaria (NEG): el modelo predijo correctamente 15 de 15 negativos pero 0 de 10 positivos en el conjunto de prueba. Las palabras con mayor coeficiente positivo fueron *gracias* (+0,67), *histórico* (+0,65) y *excelente* (+0,60); las de mayor coeficiente negativo fueron *caos*, *desastre*, *corrupción* y *prometió* ($\approx -0,36$), consistentes con el dominio de opinión pública. En la prueba con 8 casos difíciles, el modelo HuggingFace identificó correctamente el sarcasmo en «*Qué maravilla, otro día sin agua*» (NEG) y la negación en «*No puedo creer lo bien que funcionan*» (POS), mientras que TF-IDF+RL falló en 4 de los 8 casos. El TTR del corpus fue 0,60 con un 71 % de hapax legomena (596 de 839 palabras únicas aparecen una sola vez), reflejando la alta diversidad léxica típica de tweets cortos.

4. Reflexión Integradora

Los tres bloques cuentan una historia coherente sobre cómo abordar datos colombianos reales con herramientas modernas de machine learning. El Bloque 1 establece el principio fundamental de «conoce tus datos»: antes de modelar, es indispensable entender la distribución de las variables

(68 % residencial, media de 295 m², cola extrema hasta 2,8 millones de m²) para tomar decisiones informadas sobre transformaciones. Esa decisión —aplicar logaritmo al área— fue precisamente lo que permitió que el pipeline del Bloque 2 alcanzara un AUC de 0,79 con solo cuatro variables. El Bloque 2 demostró que los modelos clásicos de Spark ML, respaldados por validación cruzada rigurosa, ofrecen un balance excelente entre rendimiento predictivo y explicabilidad: el feature importance de Random Forest revela exactamente qué variables importan y por qué, algo crítico en contextos regulados como el catastral donde cada decisión debe ser auditable. El Bloque 3 amplió el alcance al mundo del texto no estructurado y mostró el trade-off fundamental del NLP moderno: TF-IDF + Regresión Logística es ligero, rápido y totalmente interpretable a través de sus coeficientes, pero no entiende contexto, sarcasmo ni negaciones; el modelo pre-entrenado de HuggingFace sí lo hace, a costa de 500 MB de memoria y sin trazabilidad directa de sus decisiones. La lección integradora es que no existe un modelo universalmente superior: la elección depende del contexto de uso. En un sistema de avalúos catastrales, donde cada peso debe justificarse, la interpretabilidad de Random Forest es irrenunciable. En un dashboard de monitoreo de redes sociales para una alcaldía, donde el sarcasmo abunda, la precisión semántica de un transformer es indispensable. Un sistema de datos maduro integraría ambos paradigmas: modelos ligeros e interpretables para decisiones estructuradas, transformers para comprender el pulso ciudadano en lenguaje natural.

5. Limitaciones

1. Tamaño y naturaleza de las muestras. El Bloque 2 se ejecutó sobre una muestra de 100.000 registros (9,4 % del dataset completo) por restricciones de memoria del entorno local (8 GB RAM, 1,6 GB disponibles). Los 9 clusters de K-Means y las métricas de clasificación reflejan patrones de esta muestra, no necesariamente de la población completa. En el Bloque 3, el corpus de 204 documentos es sintético: aunque se construyó replicando patrones reales de redes sociales colombianas, no captura la diversidad completa del discurso ciudadano ni fue validado con anotadores humanos.

2. Propagación de sesgo en knowledge distillation. Las etiquetas del Bloque 3 provienen exclusivamente del modelo robertuito, no de anotación manual. Cualquier sesgo del modelo pre-entrenado —por ejemplo, clasificar como NEU textos que un humano anotaría como NEG— se propaga directamente al clasificador TF-IDF. Un gold standard con al menos 500 ejemplos anotados manualmente permitiría medir este sesgo y calibrar las conclusiones.

3. Pobreza de variables en TUSO. El dataset contiene solo tres columnas (código del lote, tipo de uso y área). Variables adicionales como avalúo catastral, estrato socioeconómico, año de construcción, número de pisos o coordenadas geográficas —disponibles en otras capas del IDECA— enriquecerían significativamente el modelo y probablemente elevarían el AUC por encima de 0,85.

6. Recomendaciones para Replicar o Continuar

Para quien desee reproducir este análisis: use el Dockerfile incluido (*docker-compose up --build*, acceda en *localhost:8890*). Garantiza Spark 3.5.0, Python 3.10 y todas las dependencias sin conflictos de versión. Ejecute los notebooks en orden: *bloque1_eda* → *bloque2_ml* → *bloque3_nlp*, ya que el Bloque 2 reutiliza transformaciones del Bloque 1 y el Bloque 3 es independiente.

Para escalar el análisis: (a) Reemplace el corpus sintético del Bloque 3 por tweets reales obtenidos vía API de X/Twitter o scraping de portales de noticias, apuntando a ≥ 2.000 documentos. (b) Cruce TUSO con otras capas del IDECA (avalúos, estratos, coordenadas) para agregar features

que eleven el AUC del clasificador. (c) Pruebe XGBoostClassifier de Spark ML como alternativa a Random Forest; suele superarlo en datos tabulares mixtos. (d) Ejecute PCA y K-Means sobre el dataset completo en un clúster Spark con ≥ 4 núcleos para validar si la estructura de clusters se mantiene. (e) Para producción, combine ambos enfoques del Bloque 3: use HuggingFace como teacher model para generar etiquetas automáticas sobre datos nuevos, y entrene periódicamente un clasificador TF-IDF ligero que corra en producción con baja latencia y bajo costo computacional.