

Reporte Ejecutivo

Proyecto Final — Machine Learning con PySpark y Docker

Estudiante: Sergio Huertas
Curso: Machine Learning con PySpark y Docker — 2026-I
Repositorio: github.com/chechitoooo/proyecto_final_Huertas_Sergio

1. Resumen Ejecutivo

Este proyecto aplica un flujo completo de ciencia de datos sobre dos problemas del contexto colombiano: el análisis del uso del suelo en Bogotá a partir de 1 060 001 registros catastrales (TUSO) y el análisis de sentimiento sobre un corpus de 204 comentarios ciudadanos acerca de instituciones públicas. Combinando PySpark para procesamiento distribuido, Spark ML para modelado clásico y Hugging Face para transferencia de aprendizaje en NLP, se identificó que el 68 % de los predios son de uso residencial, que el área del predio explica más del 95 % de la capacidad predictiva en clasificación supervisada, y que los modelos pre-entrenados superan ampliamente a TF-IDF en la detección de sarcasmo y ambigüedad en textos informales.

2. Metodología

Bloque 1 — Análisis Exploratorio de Datos (EDA)

Se cargó el dataset TUSO.csv (Catastro Distrital de Bogotá) en PySpark con 1 060 001 registros y tres columnas: código del lote (USOCLOTE), tipo de uso (USOTUSO) y área en m² (USOAREA). Se aplicaron transformaciones con *withColumn*, *groupBy* y *filter* para clasificar predios por tamaño, derivar el sector geográfico desde el código del lote, y calcular estadísticas descriptivas. Se verificó la ausencia de nulos y duplicados, se identificaron valores atípicos extremos (máximo 2 799 947,8 m² frente a una media de 295,6 m²), y se generaron visualizaciones con Matplotlib. La elección de PySpark respondió a la necesidad de procesar más de un millón de registros de forma eficiente.

Bloque 2 — Machine Learning con Spark ML

Se construyó un pipeline de preparación con StringIndexer, OneHotEncoder, VectorAssembler y StandardScaler (preferido sobre MinMaxScaler por los outliers extremos y porque PCA requiere datos centrados en cero). En la parte no supervisada se aplicó PCA (10 componentes, 35,4 % de varianza acumulada) y K-Means con el método del codo (K=9 óptimo). Para la clasificación supervisada se definió una variable objetivo binaria (USOTUSO=1 residencial vs. resto, 68 % de la muestra) y se entrenaron Regresión Logística y Random Forest sobre 100 000 registros balanceados. Se evaluaron accuracy, precision, recall, F1 y AUC. Finalmente se aplicó validación cruzada con CrossValidator sobre una grilla de hiperparámetros (numTrees × maxDepth).

Bloque 3 — NLP y Modelo Pre-entrenado

Se construyó un corpus sintético de 204 tweets y comentarios sobre alcaldías, ministerios, TransMilenio y servicios públicos colombianos. En la Parte A se aplicó tokenización con RegexTokenizer y filtrado de stop words en español, reportando TTR (0,60) y hapax legomena (71

% del vocabulario). En la Parte B se vectorizó con CountVectorizer + IDF, comparando los rankings de TF crudo vs. TF-IDF. En la Parte C se etiquetó el corpus mediante knowledge distillation con el modelo pre-entrenado *pysentimiento/robertuito-sentiment-analysis* (Universidad de Buenos Aires) y se entrenó Regresión Logística sobre TF-IDF. En la Parte D se compararon ambos enfoques con 8 casos difíciles de sarcasmo, ambigüedad y negaciones, concluyendo con una recomendación para producción.

3. Resultados Clave

Hallazgo 1 (Bloque 1): El 68,1 % de los predios de Bogotá (721 963 de 1 060 001) corresponden al tipo de uso código 1 (residencial), con un área promedio de 187,13 m², inferior al promedio general del dataset (295,56 m²). La desviación estándar de 3 082,43 m² y el valor máximo de 2 799 947,8 m² evidencian una distribución con cola derecha extrema que exige transformación logarítmica para cualquier modelado posterior.

Hallazgo 2 (Bloque 2): El área del predio domina la clasificación de uso: en el modelo Random Forest, las variables USOAREA (39,6 %) y log_area (40,1 %) suman el 79,7 % de la importancia total, mientras que el sector geográfico (sector_ohe) apenas aporta un 4,3 %. La validación cruzada seleccionó numTrees=100 y maxDepth=15 como configuración óptima, alcanzando un AUC-ROC de 0,79 y un F1-Score de 0,85 sobre el conjunto de prueba.

Hallazgo 3 (Bloque 3): El modelo pre-entrenado de Hugging Face (robertuito) supera al pipeline TF-IDF + Regresión Logística en la clasificación de sentimiento sobre textos institucionales colombianos. Mientras TF-IDF+RL obtuvo un accuracy de 0,60 y F1 de 0,71 (sesgado hacia la clase mayoritaria), el modelo HF demostró capacidad para manejar sarcasmo («*Qué maravilla, otro día sin agua*» clasificado correctamente como NEG) y negaciones («*No puedo creer lo bien que funcionan*» como POS). Las palabras con mayor coeficiente en RL fueron *gracias* (+0,67, POS) y *corrupción* (−0,36, NEG), alineadas con el dominio de opinión pública.

4. Reflexión Integradora

Los tres bloques del proyecto están conectados por un hilo metodológico común: partir de datos crudos colombianos, transformarlos con PySpark, extraer patrones mediante técnicas estadísticas y de machine learning, y derivar recomendaciones accionables. El Bloque 1 estableció las bases del entendimiento del dato («conoce tus datos»), revelando la necesidad de transformar variables con distribuciones asimétricas antes de modelar. El Bloque 2 demostró que los modelos clásicos de Spark ML, cuando se combinan con validación cruzada rigurosa, pueden alcanzar rendimiento competitivo (AUC 0,79) con total explicabilidad a través de feature importance, lo cual es crítico en dominios regulados como el catastral. El Bloque 3 amplió el alcance al dominio no estructurado del texto, evidenciando que la transferencia de aprendizaje con modelos pre-entrenados es indispensable cuando el contexto semántico (sarcasmo, negaciones) determina la calidad de la predicción. La integración de ambos paradigmas —modelos interpretables para datos estructurados y transformers para texto— representa el estado del arte en sistemas de inteligencia de datos aplicados al sector público.

5. Limitaciones

1. Tamaño y representatividad de la muestra. Para los Bloques 2 y 3 se trabajó con muestras reducidas (100 000 y 204 registros respectivamente) debido a restricciones de memoria del entorno local. Los resultados de clasificación supervisada y análisis de sentimiento deben interpretarse

como indicativos y no como conclusiones definitivas sobre la población completa. En particular, el corpus del Bloque 3 es sintético y aunque refleja patrones reales de opinión pública, no captura la diversidad completa del discurso en redes sociales colombianas.

2. Etiquetado heurístico vs. manual. Las etiquetas de sentimiento del Bloque 3 provienen de un modelo pre-entrenado (knowledge distillation), no de anotación humana. Aunque robertuito tiene alta precisión en español, cualquier sesgo del modelo se propaga al clasificador TF-IDF entrenado sobre sus predicciones. Un gold standard con anotación manual de al menos 500 ejemplos mejoraría la validez de las conclusiones.

3. Variables disponibles en TUSO. El dataset solo contiene tres columnas, lo que limita la capacidad predictiva de los modelos. Variables adicionales como avalúo catastral, estrato socioeconómico, año de construcción o número de pisos enriquecerían significativamente el análisis y permitirían modelos con mayor poder discriminante.

6. Recomendaciones

Para quien desee replicar este análisis:

- **Use Docker desde el inicio.** El Dockerfile incluido garantiza un entorno reproducible con Spark 3.5.0, Python 3.10 y todas las dependencias. Ejecute `docker-compose up --build` y acceda a Jupyter en `localhost:8890`. Esto evita incompatibilidades de versiones de Java/PySpark que consumen horas de depuración.
- **Escale el corpus del Bloque 3.** Reemplace el corpus sintético por datos reales obtenidos mediante la API de Twitter/X o scraping de plataformas como Reddit. Un corpus de al menos 2 000 tweets con anotación manual de 500 ejemplos permitiría validar estadísticamente las diferencias entre TF-IDF y modelos transformer.
- **Enriquezca el dataset TUSO.** Cruce con otras fuentes del IDECA (Instituto Geográfico Agustín Codazzi) como avalúos, estratificación o licencias de construcción para agregar features que mejoren el AUC del clasificador, que actualmente alcanza 0,79 con solo cuatro variables.
- **Pruebe XGBoost en Spark.** Aunque Random Forest dio buenos resultados, XGBoost suele superarlo en datos tabulares con variables mixtas. Spark ML incluye `XGBoostClassifier` desde la versión 3.0.
- **Ejecute en un clúster.** El pipeline de PCA y K-Means sobre el dataset completo (1M de registros) se beneficiaría de un clúster Spark con 4+ núcleos. En local, use muestreo estratificado como se hizo en este proyecto.